AUDIT :
Erreur sur le Cube OLAP

SUPER SMART MARKET

Présentation de la mission

L’objectif de cette mission est d’auditer l’extraction à plat de la base de données OLAP de SuperSmartMarket afin de comprendre la structure des données, reconstruire un prototype de base de données local et vérifier les indicateurs affichés dans Power BI.

Le travail réalisé comprend :

- la compréhension de l’architecture data de l’entreprise ;
- la création d’un dictionnaire des données ;
- la création d’un schéma relationnel ;
- la mise en place d’un prototype SQLite ;
- l’exécution de requêtes SQL pour valider le chiffre d’affaires du 14 août 2024

Analyse de la base de données

Architecture de l’entreprise

L’entreprise SuperSmartMarket utilise une architecture data moderne basée sur :

- une base de données relationnelle
- un entrepôt de données (OLAP)
- un outil de visualisation (Power BI)

Les données sont collectées depuis les systèmes métiers, transformées et intégrées dans un cube OLAP, puis exploitées dans Power BI pour le reporting.

- flux : source → ETL → OLAP → PowerBI

Analyse de la base de données

Dictionnaire des données du fichier OLAP et schéma relationnel

DICTIONNAIRE DES DONNÉES - Clients

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
customer_id	Identifiant unique du client	VARCHAR	17	E	Clé primaire de la table Clients ; orthographe source à corriger en CUSTOMER_ID dans le modèle cible	Aucune
date_inscription	Date d'inscription du client	DATE	10	E	Date de création du compte client au format DATE (jj/mm/aaaa)	Aucune

DICTIONNAIRE DES DONNÉES - employés

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_employe	Identifiant unique de l'employé	VARCHAR	32	E	Clé primaire de la table Employé ; ne doit pas être nul	Aucune
date_debut	Date de début de contrat ou de prise de poste	DATE	10	E	Dans le fichier source, la date est stockée sous forme de numéro de série Excel ; à convertir au format DATE (jj/mm/aaaa)	Conversion du numéro de série Excel en date

Analyse de la base de données

Dictionnaire des données du fichier OLAP et schéma relationnel

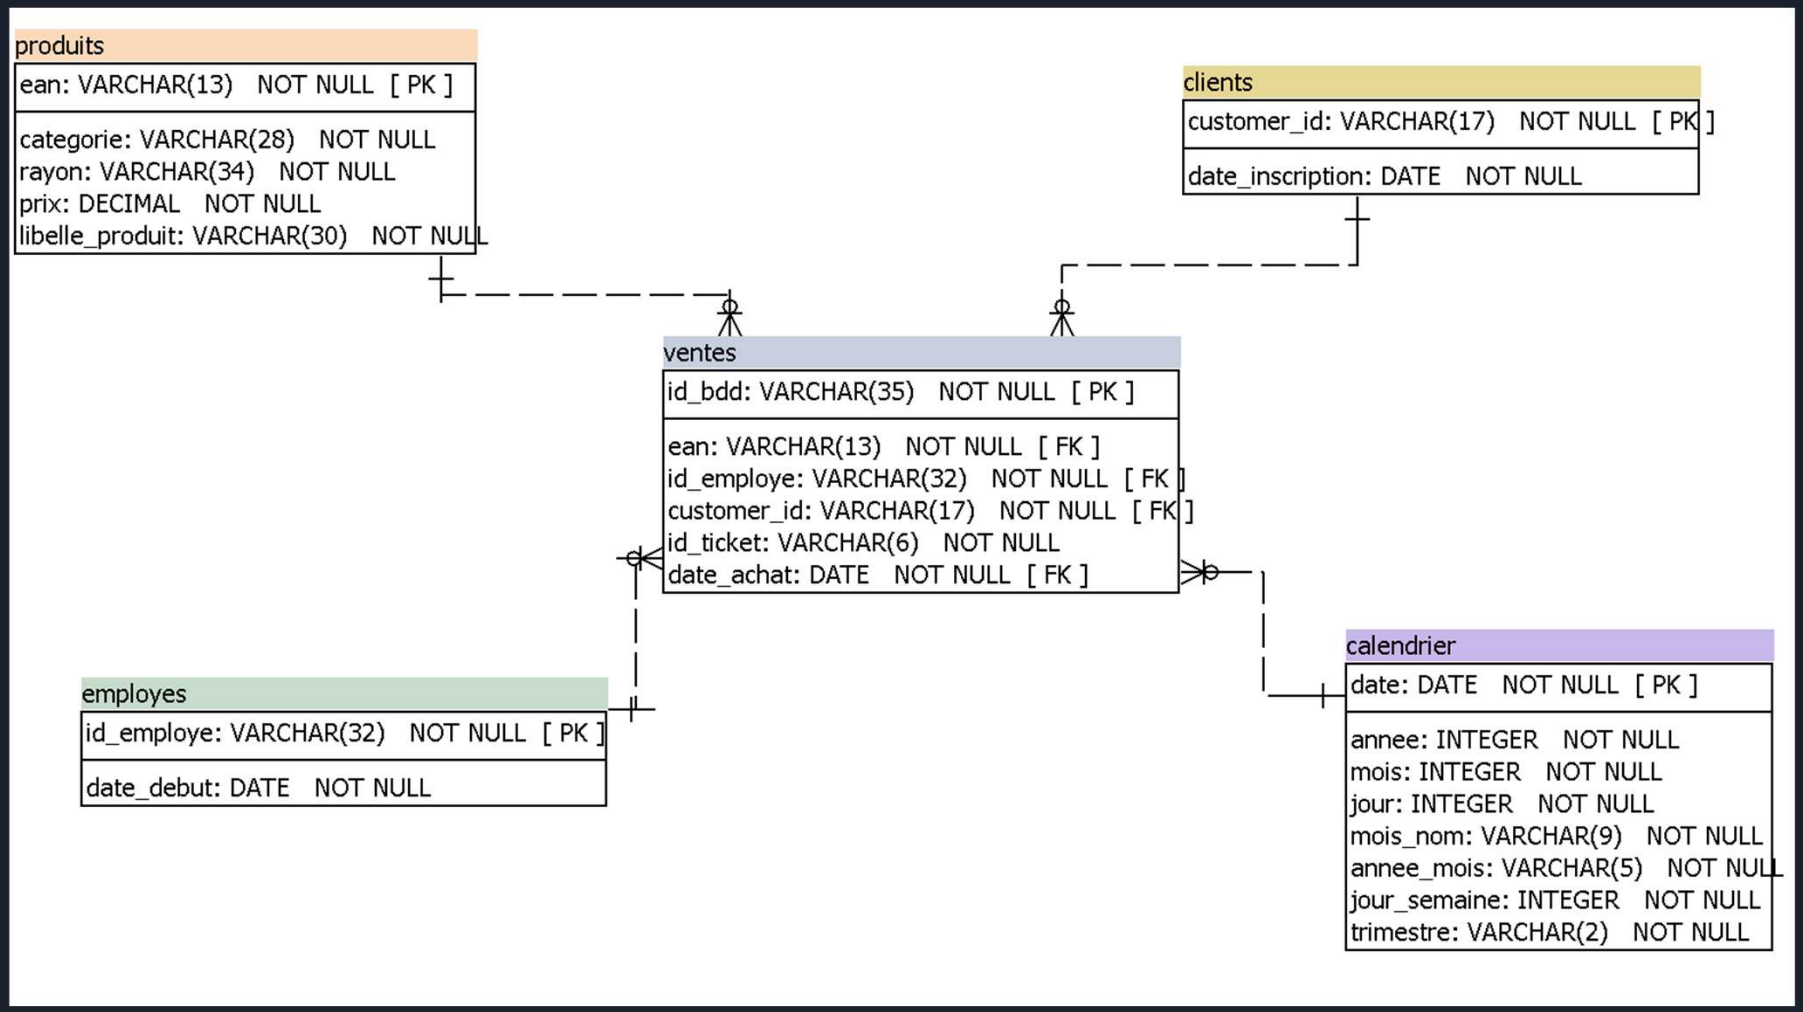

Présentation du prototype de BDD

Explication de la base de données

Un prototype de base de données a été créé en SQLite afin de reproduire localement le fonctionnement de l'extraction OLAP.

Étapes réalisées :
- création des tables
- import des fichiers CSV
- vérification des volumes
- contrôle de cohérence entre les dimensions et la table de faits.

Résultat des requêtes SQL

Le chiffre d’affaires total pour le 14 Août

```
SELECT SUM(p.prix) AS chiffre_affaires_total
FROM ventes v
JOIN produits p ON v.ean = p.ean
WHERE v.date_achat = '14/08/2024';
```

Résultat : chiffre d'affaires de 284 243.88 €

	chiffre_affaires_total
1	284243.88

Résultat des requêtes SQL

Le chiffre d’affaires par client pour le top 10 des clients

```
SELECT
    v.customer_id,
    SUM(p.prix) AS chiffre_affaires_client
FROM ventes v
JOIN produits p ON v.ean = p.ean
WHERE v.date_achat = '14/08/2024'
GROUP BY v.customer_id
ORDER BY chiffre_affaires_client DESC
LIMIT 10;
```

Résultat :

	customer_id	chiffre_affaires_client
1	CUST-JNSOZSFORR88	846.86
2	CUST-GM6VBAYAB8SF	666.86
3	CUST-L2ST2JHI7K9O	644.18
4	CUST-WU7ZKQJE4L17	608.93
5	CUST-9WM83101QDTI	582.03
6	CUST-ZMAOVX8XYGJY	576.39
7	CUST-3K66CV0OHH7Q	571.44
8	CUST-CG23SXJDRNYR	531.09
9	CUST-D8IOFHVUFX3Y	477.35
10	CUST-IHN1HQRI7PYJ	463.73

Résultat des requêtes SQL

Le chiffre d’affaires encaissé par employé

```
SELECT
    v.id_employe,
    ROUND(SUM(p.prix), 2) AS chiffre_affaires_employe,
    ROUND(
        100.0 * SUM(p.prix) /
        (
            SELECT SUM(p2.prix)
            FROM ventes v2
            JOIN produits p2 ON v2.ean = p2.ean
            WHERE v2.date_achat = '14/08/2024'
        ),
        2
    ) AS part_ca_pourcent
FROM ventes v
JOIN produits p ON v.ean = p.ean
WHERE v.date_achat = '14/08/2024'
GROUP BY v.id_employe
ORDER BY chiffre_affaires_employe DESC;
```

	id_employe	chiffre_affaires_employe	part_ca_pourcent
1	f491076a1ff2d873ebea809c11144542	7818.82	2.75
2	e01e752175e05f00c8314ccb8da4c418	7736.16	2.72
3	8d1001fbad3d2a60ff7530600ed5d55e	6995.14	2.46
4	6c1c3292c852c6c593b95cc146b00c0e	6616.46	2.33
5	a7ada0770091e838e3dcd45265282820	6483.84	2.28
6	2477db17c02f512ebc4b20f01a7edb55	6361.22	2.24
7	528c733809cb51a3634befb260b5d243	6133.34	2.16
8	1c1d83678cc463b52366dae07cd14c8a	6112.37	2.15
9	dd595f0f0b3400df2908f0be7723dad4	6111.18	2.15
10	c4f0909120cfde7086a3c1a56e96a015	6094.62	2.14
11	4853b03deab973a1a8e466025bce5b52	5989.84	2.11
12	3084187cfabdb2a7de260f4387241ccc	5936.36	2.09
13	f6cd8ba3485769b3ad9bab5b7725858e	5909.73	2.08
14	658e6925c1774feb2781a2888c9d4202	5827.75	2.05
15	4efc10ff0f86c772d9949b490eb99ad3	5734.83	2.02
16	c495d16c3108a11ac8318269a85e9706	5705.28	2.01

Analyse des logs
Dictionnaire des données et explications

Les logs ont été intégrés dans la base de données afin d'analyser les modifications effectuées sur les données.
Chaque ligne de log correspond à une action réalisée sur une table (INSERT, UPDATE, DELETE).
Les principales informations présentes dans les logs sont :

- **id_user** : identifiant de l'utilisateur ayant effectué l'action
- **date** : la date de l'action
- **action** : le type d'action (INSERT, UPDATE, DELETE)
- **table_insert** : la table concernée
- **id_ligne** : ligne impactée
- **champs** : le champ modifié
- **detail** : détail de la modification

Analyse des logs
Dictionnaire des données et explications

1) Nombre de logs : 207 489 logs

```
SELECT COUNT(*) FROM logs;
```

	COUNT(*)
1	207489

2) Nombre de logs par action :

```
SELECT action, COUNT(*)
FROM logs
GROUP BY action;
```

	action	COUNT(*)
1	DELETE	2
2	INSERT	206905
3	UPDATE	582

3) Explication des logs (quelle table, quelle modification…)

```
SELECT
   table_insert,
   champs,
   action,
   COUNT(*) AS nb_logs
FROM logs
GROUP BY table_insert, champs,
action
ORDER BY nb_logs DESC;
```

	table_insert	champs	action	nb_logs
1	Ventes	CUSTUMER_ID	INSERT	41377
2	Ventes	Date	INSERT	41377
3	Ventes	EAN	INSERT	41377
4	Ventes	ID ticket	INSERT	41377
5	Ventes	id_employe	INSERT	41377
6	Produits	prix	UPDATE	575
7	Client	date_inscription	INSERT	20
8	Employé	hash_mdp	UPDATE	7
9	Employé		DELETE	2

L'analyse des logs permet d'identifier les principales tables et types de modifications enregistrées dans la base.
On observe notamment des opérations d'insertion sur les ventes et des mises à jour sur les produits.
Cette analyse exploratoire permet de mieux comprendre le fonctionnement de la base avant d'identifier la cause précise de l'écart observé.

Compréhension des problèmes sur la base des logs

L’analyse des logs montre que les données peuvent être modifiées ou ajoutées après leur enregistrement initial. Cela rend certains indicateurs, comme le chiffre d’affaires journalier, susceptibles d’évoluer dans le temps. Une analyse complémentaire a permis d’identifier plus précisément un décalage d’intégration sur certaines ventes.

Analyse du décalage du chiffre d'affaires

Objectif : Identifier l'origine de l'écart de chiffre d'affaires observé entre deux dates

Résultat

Écart calculé : 9 057,29 €

Ce montant correspond exactement à la différence entre :
275 186,59 € (CA initial)
284 243,88 € (CA mis à jour)

Analyse

Les logs montrent que certaines ventes ont été **insérées le 15/08 (45519)**.
Ces ventes correspondent en réalité à des transactions du **14/08 (45518)**.
Elles n'étaient donc **pas présentes lors du calcul initial du chiffre d'affaires**.

Conclusion

- Le chiffre d'affaires du 14/08 était **incomplet lors du premier calcul**.
- Des ventes ont été **intégrées avec un jour de retard**.
- le recalcul du chiffre d'affaires a intégré ces ventes enregistrées avec un décalage, confirmant un retard d'intégration des données.

```
SELECT SUM(produits.prix) AS Ecart
FROM logs
LEFT JOIN produits ON logs.detail = produits.ean
WHERE logs.champs = 'EAN'
  AND logs.id_ligne IN (
    SELECT id_ligne
    FROM logs
    WHERE action = 'INSERT'
      AND date = '45519'
);
```

	Ecart
1	9057.29

Recommandations pour l’entreprise

- Actions à mettre en place

- Mettre en place une table d’historisation des prix des produits
- Ajouter une colonne prix_unitaire dans la table ventes
- Alimenter cette colonne avec le prix au moment de la vente
- Modifier le calcul du chiffre d’affaires
- Mettre en place des contrôles sur la cohérence des données

Recommandations pour l'entreprise

- Prototype

La solution d'historisation des prix est la recommandation principale, mais elle nécessite une évolution plus complexe du modèle de données.
Le prototype présenté se concentre sur le stockage du prix dans la table ventes, qui constitue une solution simple permettant d'illustrer concrètement l'impact sur le chiffre d'affaires.

Mise en place :

```
ALTER TABLE ventes ADD COLUMN prix_unitaire REAL;

UPDATE ventes
SET prix_unitaire = (
   SELECT produits.prix
   FROM produits
   WHERE produits.ean = ventes.ean
);
```

Test réalisé :

```
UPDATE produits
SET prix = prix + 10
WHERE ean = '2597945667827';
```

Calcul avec ventes.prix_unitaire : stable

	SUM(v.prix_unitaire)
1	284243.88

Calcul avec produits.prix : modifié

	SUM(p.prix)
1	284283.88

Le calcul basé sur produits.prix a augmenté de **40 €**
Le calcul basé sur ventes.prix_unitaire est resté stable
Le produit a été vendu **4 fois**, ce qui explique l'écart

Recommandations pour l’entreprise

Avantages et inconvénients de la solution

Avantages :

-Stabilisation du chiffre d’affaires
-Meilleure fiabilité des données
-Cohérence des analyses dans le temps
-Solution simple et rapide à mettre en place (prototype)

Inconvénients :

-Solution moins complète qu’une historisation des prix
-Nécessite une adaptation des processus de chargement
-Augmentation du volume de données (dans le cas d’une historisation complète)

Recommandations pour l’entreprise

Implications pour l’organisation actuelle

- Évolution du modèle de données avec mise en place d’une historisation des prix
- Implication de l’équipe data pour adapter la base et les traitements
- Adaptation des processus ETL pour intégrer les nouvelles données
- Mise en place de contrôles de qualité des données

Recommandations pour l'entreprise

Planning de mise en place et coût éventuel

Court terme : Faible coût

- Ajout de la colonne prix_unitaire dans la table ventes
- Modification des requêtes de calcul du chiffre d'affaires

Moyen terme : Coût modéré

- Mise en place de l'historisation des prix
- Adaptation du modèle de données

Long terme : Coût plus élevé

- Amélioration continue de la qualité des données
- Mise en place de contrôles et de suivi des indicateurs

Le coût dépend principalement du temps de développement, des adaptations des flux ETL et des phases de test.

Conclusion

- *Le projet a permis d'identifier une incohérence dans le calcul du chiffre d'affaires*
- *L'analyse des données et des logs a mis en évidence un retard d'intégration des ventes*
- *Un prototype a été mis en place afin de corriger ce problème*
- *Ce prototype permet de stabiliser le chiffre d'affaires en utilisant le prix au moment de la vente*
- *La mise en place d'une historisation des prix constitue une solution plus robuste pour garantir la stabilité des indicateurs dans le temps*
- *Les recommandations proposées améliorent la fiabilité des données et la qualité des analyses*
- *Ce travail met en évidence l'importance de la qualité des données dans les systèmes décisionnels*